

Siri 的困局与重生

苹果在 WWDC 2026 上宣布了 Siri 的全面重构——从基于规则的意图识别引擎切换到 LLM 生成式架构。这是一次被迫的追赶。旧 Siri 的问题不是功能缺失，而是底层架构无法支撑自然语言理解。新 Siri 能否成功，取决于它在任务完成率、上下文连续性和开发者生态三个维度上的表现。

25% 准确率差距 旧 Siri 落后于 ChatGPT	14 年 Siri 已存在 2011 年随 iPhone 4S 发布	2026.9 预计上线时间 随 iOS 27 正式推送	Gemini 底层技术合作 Google 提供模型能力
--	--	--	--

I. 旧 Siri 的运作逻辑

1. 意图识别架构

Siri 的核心是一个基于规则的 NLP 意图匹配系统。用户输入被解析为预定义的 "App Intents"——设闹钟、发消息、查天气。系统将特定短语映射到特定动作。一旦用户偏离预设表达模式，Siri 就无法理解。

这和 ChatGPT、Claude 等生成式模型的工作方式截然不同。后者理解语义，前者匹配模式。

2. 无状态交互

每次对话都是独立的。Siri 没有上下文记忆。你不能说 "把刚才那个发给小明"——Siri 不知道 "刚才那个" 是什么。每次请求都要从零开始描述完整意图。这让多步骤操作几乎不可能完成。

3. 单任务串行

Siri 一次只能处理一个请求。无法链式执行跨应用操作。用户想做的事越复杂，就越需要手动拆分成多个独立指令逐一执行。实际使用场景因此被压缩到 "设闹钟""播音乐" 等极简操作。

II. 问题出在哪里

1. ChatGPT 的冲击与仓促应对

据 Bloomberg 报道，苹果在 ChatGPT 发布前没有 Apple Intelligence 的计划。2022 年底 ChatGPT 上线后，软件副总裁 Craig Federighi 在用它写代码时才意识到生成式 AI 的潜力。随后苹果紧急组建团队，开始与 OpenAI、Anthropic 等公司接触，并要求 iOS 18 尽可能多地加入 AI 功能。^[1]

2. 新旧代码无法合并

核心技术债

工程师将 Siri 的基础设施一分为二来加入 AI 功能，合并时系统崩溃。新的

AI 能力和旧的遗留功能（如设闹钟）运行在不同架构上，集成时出现大量冲突。这是一个典型的技术债务问题——14 年的遗留代码无法承载全新的架构范式。^[1]

3. 领导层判断失误

前 AI 负责人 John Giannandrea 对生成式 AI 缺乏紧迫感。他认为消费者不信任生成式 AI，AI agent 离取代人类还很远。内部测试显示苹果自研聊天机器人准确率比 ChatGPT 低 25%。Tim Cook 最终在 2025 年 3 月撤换了他，由 Vision Pro 负责人 Mike Rockwell 接管。^[1]

4. 营销与工程脱节

苹果不得不撤下 iPhone 16 的 AI 功能广告，因为那些功能还没做好。多次延期导致集体诉讼——用户以"虚假宣传 AI 能力"为由起诉苹果。这是产品团队和市场团队之间缺乏协调的直接后果。

“

"挑战不在于模型质量，而在于热量包络。在移动芯片上运行高参数模型需要激进的量化和高效的内存交换。"

硅谷基础设施集团首席系统架构师

III. 新 Siri 的解决方案

1. 全新 LLM 架构 根本性重构

苹果苏黎世团队正在构建全新的、完全基于 LLM 的 Siri 引擎，彻底抛弃旧架构。不再是给旧系统打补丁，而是从底层重写。新架构采用 Google Gemini 技术提供核心生成能力，由 Google Cloud + Nvidia 芯片驱动。
[2]

2. 三大能力支柱

世界知识、个人上下文、可执行智能。

- 世界知识：RAG（检索增强生成）系统交叉验证 LLM 输出与可信知识图谱，减少幻觉
- 个人上下文：持久化上下文窗口，支持打断、换话题、回到之前内容，像和人对话而非查询搜索引擎
- 可执行智能：跨应用链式任务——"找到上周下载的 PDF，总结其中一段，邮件发给项目经理并附上下周二的会议邀请"

3. 混合计算架构

隐私敏感的请求在设备端 Neural Engine 处理；复杂推理交给 Private Cloud Compute。PCC 是苹果的 Apple Silicon 服务器，处理请求但不存储数据——苹果自己也无法访问查询内容。个人数据（消息、备忘录）永远不离开设备。
[3]

4. 独立 Siri App + 内置搜索

苹果将推出独立的 Siri 应用（iOS/iPadOS/macOS），直接对标 ChatGPT 和 Claude。同时首次推出内置 Web 搜索引擎，与 Perplexity 竞争——Siri 可以用自有引擎回答任何问题，返回摘要、列表和图片，而不是把用户跳转到 Google。
[4]

5. AI Agent 应用商店

苹果计划将 AI Agent 集成到 App Store。第三方应用通过 App Intents API 将内部功能暴露给 Siri 的 LLM，让 Siri 可以在 Uber、Photoshop 等应用内部导航和执行操作，用户无需触碰屏幕。
[2]

IV. 新旧架构对比

关键维度变化

维度	旧 SIRI	新 SIRI (IOS 27)
核心架构	意图匹配 (NLP 规则)	LLM 生成式模型
上下文记忆	无状态，每次独立	持久化上下文窗口
任务能力	单任务串行	跨应用链式执行
知识来源	预编程数据库	RAG + 内置搜索引擎
多模态	仅语音/文字	语音 + 屏幕感知 + 相机
推理位置	主要云端	混合：设备端 + PCC
三方集成	有限 SiriKit	App Intents API + Agent Store
竞品对标	Google Assistant / Alexa	ChatGPT / Claude / Perplexity

V. 成败衡量指标

1. 任务完成率	核心指标	用户发出的请求中，Siri 能正确完成多少？旧 Siri 的问题不是速度，是根本做不了用户想做的事。这个数字需要和 ChatGPT、Gemini、Claude 做横向对比。苹果内部测试曾显示 25% 的准确率差距——新 Siri 至少需要追平。
2. 多步骤任务成功率		链式操作是新 Siri 的核心价值主张。能否真正执行"搜索文件→总结内容→发邮件→创建日历事件"这样的四步链？失败率是多少？在哪一步断裂？这直接决定用户是否愿意把复杂任务委托给 Siri。
3. 日均调用频次		每台设备每天 Siri 被主动调用多少次？旧 Siri 的问题是用户学会了"不用它"。如果新 Siri 真的有用，这个数字应该显著上升。还需要区分"主动调用"和"被动触发"（误唤醒）。
4. "兜底率"下降		Siri 回复"我在网上找到了这些"的比例应该大幅下降。旧 Siri 大量将查询转交给 Google 搜索。新 Siri 有了内置搜索引擎和 RAG 系统，直接在对话内给出答案的比例是衡量知识能力的关键指标。
5. 开发者 API 采用率		多少第三方应用接入了 App Intents API？Siri 的生态价值取决于它能在多少应用内执行操作。如果只有苹果自家应用支持，Agent 能力就是空谈。需要追踪 Top 100 应用中的接入比例和接入深度。
6. 隐私合规指标		设备端处理的请求占比。苹果的差异化竞争力是隐私。iOS 27 引入了"Intelligence Report"，让用户看到哪些请求在设备端处理、哪些发到了云端。设备端占比越高，隐私承诺越可信。
7. 响应延迟		从用户发出请求到 Siri 开始回答的时间。设备端推理应该接近零延迟；云端 PCC 请求的往返时间（RTT）需要控制在用户感知阈值内。M5/M4 芯

片的 NPU 性能和热管理直接影响这个指标。

VI. 值得关注的风险

信任赤字	Siri 已经教会了用户不去使用它。14 年的低质量体验形成了肌肉记忆——人们默认 Siri 不行。即使新 Siri 在技术上追平了竞品，重建用户信任比构建技术本身更难。苹果需要一个足够震撼的"moment"来打破这个认知。
硬件限制	完整 LLM 功能仅限最近 3 代 iPhone Pro。老设备只能使用云端依赖的降级版本，延迟更高、功能更少。这意味着大量存量用户无法体验新 Siri 的完整能力，分裂了用户体验。
再次延期的可能	Siri 升级已经延期过一次。原定 2025 年推出的 LLM Siri 被推迟到 2026 年。考虑到苹果之前在 Apple Intelligence 上的执行历史——功能宣布后多次跳票、广告被撤——市场对"9 月上线"这个时间表持观望态度。

